

# Teoría de la Información

## Ejercicios Tema 1

Antonio Coín Castro

30 de octubre de 2020

**Ejercicio 1.** Sea  $X \sim \mathcal{N}(\mu, \sigma^2)$ . Probar que la entropía de  $X$  viene dada por

$$S(X) = \frac{1}{2} \log_2(2\pi e \sigma^2).$$

*Solución.* Sabemos que en el caso continuo la entropía se calcula como

$$S = - \int_{\mathcal{X}} f(x) \log_2 f(x) dx.$$

En nuestro caso  $\mathcal{X} = \mathbb{R}$  y  $f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$ , y usando que  $\log_b x = \log_c x / \log_c b$  se tiene:

$$\begin{aligned} S &= - \int_{\mathbb{R}} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \frac{1}{\log 2} \log \left( \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \right) dx \\ &= - \frac{1}{\log 2} \left( \int_{\mathbb{R}} f(x) \log \left( \frac{1}{\sqrt{2\pi}\sigma} \right) dx - \int_{\mathbb{R}} f(x) \frac{(x-\mu)^2}{2\sigma^2} dx \right) \\ &= - \frac{1}{\log 2} \left( \log \left( \frac{1}{\sqrt{2\pi}\sigma} \right) \underbrace{\int_{\mathbb{R}} f(x) dx}_{=1} - \frac{1}{2\sigma^2} \underbrace{\int_{\mathbb{R}} f(x)(x-\mu)^2 dx}_{=\mathbb{E}[(X-\mu)^2]} \right) \\ &= \frac{-\log \left( \frac{1}{\sqrt{2\pi}\sigma} \right)}{\log 2} + \frac{\text{Var}[X]}{2\sigma^2 \log 2} = \frac{\log(\sqrt{2\pi}\sigma)}{\log 2} + \frac{\sigma^2}{2\sigma^2 \log 2} \\ &= \log_2(\sqrt{2\pi}\sigma) + \frac{\log e}{2 \log 2} = \log_2(\sqrt{2\pi}\sigma) + \frac{1}{2} \log_2 e \\ &= \frac{1}{2} (\log_2((\sqrt{2\pi}\sigma)^2) + \log_2 e) = \frac{1}{2} \log_2(2\pi\sigma^2 e). \end{aligned}$$

**Ejercicio 2.** Probar que la información mutua promedio  $MI(X, Y)$  entre dos variables aleatorias  $X$  e  $Y$  es simétrica.

*Solución.* Es consecuencia directa de la definición, entendiendo que los símbolos  $p(x, y)$  y  $p(y, x)$  representan la misma distribución conjunta  $(X, Y)$ :

$$MI(X, Y) = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y) \log_2 \left( \frac{p(x, y)}{p(x)p(y)} \right) = \sum_{y \in \mathcal{Y}} \sum_{x \in \mathcal{X}} p(y, x) \log_2 \left( \frac{p(y, x)}{p(y)p(x)} \right) = MI(Y, X),$$

donde hemos podido intercambiar las sumas ya que son numerables y todos los sumandos son no negativos. En efecto, como

$$p(x, y) = p(x|y)p(y) = p(y|x)p(x)$$

sabemos que  $p(x, y) \geq p(x)$  y también que  $p(x, y) \geq p(y)$ , luego  $p(x, y) \geq p(x)p(y)$ , y el argumento del logaritmo en la expresión de  $MI(X, Y)$  es mayor o igual que 1.

En el caso continuo se llega a la misma conclusión aplicando el teorema de Fubini para intercambiar el orden de las integrales.

**Ejercicio 3.** Probar que  $MI(X, Y) = S(X) + S(Y) - S(X, Y)$  para dos variables aleatorias  $X$  e  $Y$ .

*Solución.* Tenemos que:

$$\begin{aligned}
MI(X, Y) &= \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y) \log_2 \left( \frac{p(x, y)}{p(x)p(y)} \right) \\
&= \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y) (\log_2 p(x, y) - \log_2 p(x) - \log_2 p(y)) \\
&= \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y) \log_2 p(x, y) - \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y) \log_2 p(x) - \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y) \log_2 p(y) \\
&= -S(X, Y) - \sum_{x \in \mathcal{X}} \log_2 p(x) \sum_{y \in \mathcal{Y}} p(x, y) - \sum_{y \in \mathcal{Y}} \log_2 p(y) \sum_{x \in \mathcal{X}} p(x, y) \\
&= -S(X, Y) - \sum_{x \in \mathcal{X}} \log_2 p(x) p(x) - \sum_{y \in \mathcal{Y}} \log_2 p(y) p(y) \\
&= -S(X, Y) + S(X) + S(Y).
\end{aligned}$$

El caso continuo es totalmente análogo.

**Ejercicio 4.** Probar las siguientes propiedades para dos variables aleatorias  $X$  e  $Y$ :

- (i)  $S(X, Y) = S(X) + S(Y|X) = S(Y) + S(X|Y)$ .
- (ii)  $MI(X, Y) = S(X) - S(X|Y) = S(Y) - S(Y|X)$ .
- (iii)  $MI(X, X) = S(X)$ .

*Solución.* A partir de ahora abreviaremos la notación de los subíndices en las sumatorias. En primer lugar comprobaremos (i), usando repetidamente que  $p(x, y) = p(y|x)p(x)$ . Se tiene que:

$$\begin{aligned}
S(X, Y) &= - \sum_{xy} p(x, y) \log_2 p(x, y) = - \sum_{xy} p(x, y) \log_2 (p(y|x)p(x)) \\
&= - \sum_{xy} p(x, y) \log_2 p(x) - \sum_{xy} p(y|x)p(x) \log_2 p(y|x) \\
&= - \sum_x \log_2 p(x) p(x) - \sum_x p(x) \sum_y p(y|x) \log_2 p(y|x) \\
&= S(X) + S(Y|X).
\end{aligned}$$

Para probar la otra igualdad hacemos lo análogo pero esta vez descomponiendo  $p(x, y) = p(x|y)p(y)$ . Para ver (ii) observamos que:

$$\begin{aligned}
MI(X, Y) &= \sum_{xy} p(x, y) \log_2 \left( \frac{p(x|y)}{p(x)} \right) \\
&= \sum_{xy} p(x, y) (\log_2 p(x|y) - \log_2 p(x)) \\
&= \sum_{xy} p(x|y)p(y) \log_2 p(x|y) - \sum_x \log_2 p(x)p(x) \\
&= -S(X|Y) + S(X).
\end{aligned}$$

La otra igualdad se obtiene intercambiando los papeles de  $X$  e  $Y$  en la igualdad ya probada, recordando que la información mutua es simétrica. Por último, (iii) es una simple comprobación, teniendo en cuenta que  $p(x|x) = 1$  para todo  $x \in \mathcal{X}$ . En efecto, utilizando (ii) tenemos que:

$$\begin{aligned}
MI(X, X) &= S(X) - S(X|X) = S(X) + \sum_x p(x) \sum_x p(x|x) \log_2 p(x|x) \\
&= S(X) + \sum_x p(x) \cdot 0 = S(X).
\end{aligned}$$

Todas las propiedades para el caso continuo se demuestran de forma análoga.

**Ejercicio 5.** En el contexto de *temporal coding*, probar que cuando  $r\Delta t \ll 1$ , entonces la entropía viene dada por

$$S \approx Tr \log_2 \left( \frac{e}{r\Delta t} \right).$$

*Solución.* En primer lugar establecemos el marco de trabajo. Supondremos que tenemos un tren de spikes de longitud fija  $T$ , dividido en *bins* o ventanas de tamaño  $\Delta t$ , lo que significa que tendremos en total  $M = T/\Delta t$  ventanas. Codificaremos la presencia de *spikes* con un 1 y su ausencia con un 0, y supondremos que en cada ventana puede haber como mucho un *spike*. Así, las observaciones de las que disponemos son cadenas binarias de longitud  $M$ .

Definimos además el concepto de *firing rate* como la frecuencia de *spikes* observados en la muestra completa, es decir,

$$r = \frac{\#\text{spikes}}{T}.$$

De esta forma, la probabilidad de ocurrencia de un *spike* en una ventana puede expresarse como su frecuencia de ocurrencia, es decir,

$$p = \frac{\#\text{spikes}}{M} = \frac{\#\text{spikes}}{T/\Delta t} = r\Delta t.$$

En lo sucesivo, supondremos para que las aproximaciones que hacemos tengan sentido que la probabilidad de ocurrencia de un *spike* en una ventana es muy baja (cosa que se corresponde con el comportamiento real de las neuronas), es decir, que  $r\Delta t \ll 1$ . Esto podemos conseguirlo en la práctica tomando un tamaño suficientemente pequeño de ventana.

Para estimar la entropía, supondremos que la cadena observada ha sido extraída aleatoriamente y de manera uniforme de entre todas las posibles cadenas con el mismo número de 1s y 0s. Dicho de otra forma, todos los eventos considerados son equiprobables con probabilidad dada por el inverso del número de tales cadenas binarias distintas posibles, es decir,

$$p(x_i) = \frac{1}{\binom{M}{Tr}}, \quad i = 1, \dots, \binom{M}{Tr}.$$

En el caso de sucesos equiprobables sabemos que la entropía viene dada por el logaritmo binario del número total de eventos. Si llamamos por comodidad  $M_1 = Tr$  al número de 1s y  $M_0 = M - M_1$  al número de 0s, se tiene que

$$S = \log_2 \left( \frac{M}{M_1} \right) = \log_2 \left( \frac{M!}{M_0! M_1!} \right) = \frac{1}{\log 2} (\log M! - \log M_0! - \log M_1!). \quad (1)$$

Si suponemos que las cadenas observadas son suficientemente largas, podemos usar la **fórmula de Stirling** para aproximar  $\log x!$ , que toma la forma

$$\log x! = x(\log x - 1) + \mathcal{O}(\log x),$$

donde el resto es despreciable cuando  $x \rightarrow \infty$ . Sustituyendo esta aproximación en (1) tenemos:

$$\begin{aligned} S &\approx \frac{1}{\log 2} (M(\log M - 1) - M_0(\log M_0 - 1) - M_1(\log M_1 - 1)) \\ &= \frac{1}{\log 2} (M \log M - M_0 \log M_0 - M_1 \log M_1 + (M_0 + M_1 - M)) \\ [M = M_0 + M_1] \quad &= \frac{1}{\log 2} (M_1(\log M - \log M_1) + M_0(\log M - \log M_0)) \\ &= -\frac{M}{\log 2} ((M_1/M) \log(M_1/M) + (M_0/M) \log(M_0/M)) \\ [p = M_1/M] \quad &= -\frac{M}{\log 2} (p \log p + (1 - p) \log(1 - p)) \\ [M = T/\Delta t; p = r\Delta t] \quad &= -\frac{T}{\Delta t \log 2} (r\Delta t \log(r\Delta t) + (1 - r\Delta t) \log(1 - r\Delta t)). \end{aligned} \quad (2)$$

Ahora podemos considerar el desarrollo en serie de Taylor de la función  $\log(1 + x)$ , es decir,  $\log(1 + x) = x + \mathcal{O}(x^2)$ . Identificando  $x = -r\Delta t$  y dado que estamos suponiendo que  $r\Delta t$  es pequeño ( $\ll 1$ ), podemos considerar que el resto de Taylor es despreciable. Sustituyendo la aproximación en (2) nos queda:

$$\begin{aligned} S &\approx -\frac{T}{\Delta t \log 2} (r\Delta t \log(r\Delta t) + (1 - r\Delta t)(-r\Delta t)) \\ &\approx -\frac{T}{\Delta t \log 2} (r\Delta t \log(r\Delta t) - r\Delta t), \end{aligned} \quad (3)$$

donde de nuevo despreciamos los términos proporcionales a  $(r\Delta t)^2$ . Finalmente simplificamos la expresión (3) para obtener lo que queríamos:

$$\begin{aligned} S &\approx -\frac{T}{\Delta t \log 2} r\Delta t (\log(r\Delta t) - 1) \\ &= -\frac{Tr}{\log 2} (\log(r\Delta t) - \log e) \\ &= \frac{Tr}{\log 2} \log \left( \frac{e}{r\Delta t} \right) \\ &= Tr \log_2 \left( \frac{e}{r\Delta t} \right). \end{aligned}$$

**Ejercicio 6.** Demostrar la regla de la cadena para la entropía condicionada con tres variables aleatorias  $X, Y$  y  $Z$ , es decir,

$$S(X, Y|Z) = S(X|Z) + S(Y|X, Z).$$

*Solución.* Utilizando la definición de probabilidad condicionada y la regla del producto, podemos escribir:

$$p(x, y|z) = \frac{p(z)p(x|z)p(y|x, z)}{p(z)} = p(x|z)p(y|x, z).$$

Tomando logaritmos en la expresión anterior tenemos que

$$\log_2 p(x, y|z) = \log_2 p(x|z) + \log_2 p(y|x, z),$$

y tomando ahora esperanzas a ambos lados (sobre la distribución conjunta  $(X, Y, Z)$ ) se tiene:

$$\mathbb{E} [\log_2 p(x, y|z)] = \mathbb{E} [\log_2 p(x|z)] + \mathbb{E} [\log_2 p(y|x, z)].$$

Atendiendo a la definición de entropía condicionada, la expresión anterior es equivalente a lo que queríamos probar, es decir,

$$S(X, Y|Z) = S(X|Z) + S(Y|X, Z).$$

*Solución alternativa.* También podemos entender el resultado como una consecuencia directa de la regla de la cadena para dos variables,

$$S(X, Y) = S(X) + S(Y|X).$$

En efecto, esta regla para tres variables nos dice que

$$S(X, Y, Z) = S(Z) + S(X, Y|Z),$$

y sucesivas aplicaciones de la misma nos permiten escribir:

$$\begin{aligned} S(X, Y, Z) &= S(Z) + S(X, Y|Z) \iff \\ S(X, Z) + S(Y|X, Z) &= S(Z) + S(X, Y|Z) \iff \\ S(Z) + S(X|Z) + S(Y|X, Z) &= S(Z) + S(X, Y|Z) \iff \\ S(X|Z) + S(Y|X, Z) &= S(X, Y|Z). \end{aligned}$$

Notamos que tanto esta demostración como la anterior son válidas también en el caso continuo.